

TR-FactBench 480 Altın Veri Kümesi ve Gemma-4 Atomizasyon Analiz Raporu

Tarih: 6 Ekim 2026

Yazar: Engin Dalga

Danışman: Prof. Dr. Serkan Ballı

Çalışma: Türkçe Halüsinasyon Tespiti İçin Kademeli Hibrit Mimari (Doktora Tezi)

Veri Kümesi: TR-FactBench Gold Release Freeze v1.0 (480 Vaka)

1. Yönetici Özeti ve Giriş

Bu rapor; Türkçe Doğal Dil İşleme literatüründe olgu doğrulama (*fact-checking*) ve halüsinasyon tespiti için oluşturulan **TR-FactBench 480 Altın Veri Kümesi'nin (GOLD v1.0)** veri kalitesini, sentaktik-morfolojik zorluk seviyesini, iddia uzunluk profilini ve **Gemma-4 QLoRA Önerme Ayırıştırıcısı (Atomizer)** tarafından üretilen atomik bileşenleri istatistiksel ve kuramsal olarak incelemektedir.

Yapılan ampirik incelemeler sonucunda elde edilen temel bulgular şunlardır: 1. **İddiaların Niteliksel Yapısı:** Veri kümesindeki iddialar kesinlikle yüzeysel ya da kısa ifadelerden ibaret değildir. İddiaların **%85.8'i 13 kelime ve üzerindedir** (ortalama 17.3 kelime, 134.6 karakter; maksimum 41 kelime). İddialar, resmi metinlere dayalı çoklu yargılar ve karmaşık yan cümlecikler içermektedir. 2. **Atomizasyon Kapsaması ve Doğruluğu:** Yerel GPU üzerinde çalışan Gemma-4 QLoRA Atomizer, 480 vakanın tamamında **%100.0 kapsama oranı (0 başarısızlık)** sergileyerek toplam **998 atomik önerme** üretmiştir (iddia başına ortalama 2.08 atom). 3. **2-Atomda Toplanma Fenomeni:** İddiaların **%72.92'si (350 vaka)** tam olarak 2 atomik önermeye ayrılmaktadır. Bu dağılım tesadüfi olmayıp, halüsinasyon olgusunun temel bilişsel mekanizması olan "*doğru bir gerçeğin yanına eklenen uydurma/çelişkili ek önerme*" yapısıyla (**partially_supported** mimarisi) doğrudan örtüşmektedir. 4. **Sentaktik Bütünlük ve Özne Tamamlama:** Gemma-4 Atomizer'ı Türkçe sondan eklemeli dil yapısında düşürülen özneleri ve tamlamaları (*subject elision restoration*) başarıyla bağımsız önermeler haline getirmiş; anlamsız parçalanmaları (*over-segmentation*) önlemiştir (4+ atomlu vaka sayısı: 0). 5. **Veri Kümesinin Zorluk Düzeyi:** Çift kör insan denetçiler arasında dahi **%10.0 uyumsuzluk** barındıran ($\kappa = 0.8666$) veri kümesi, tekil modelleri (ELECTRA-TR %83.12, mDeBERTa %80.42) ciddi biçimde zorlamakta ve %25.62 oranında (123 vaka) uyumsuzluk üreterek Meta-Hakem mekanizmasının lüzumunu ispatlamaktadır.

2. Veri Kümesi Mimarisi ve Kalite Standartları

TR-FactBench 480, **GOLD_FREEZE_RECORD_TR_v1.0** protokolü ile dondurulmuş ve SHA-256 kriptografik özetleriyle güvenceye alınmış bir altın standart kıyaslama zemini.

2.1. İnsanlar Arası Güvenilirlik ve Çift Kör Denetim

- Denetçi Yapısı:** 480 vakanın tamamı iki uzman insan denetçi (Annotator A ve Annotator B) tarafından bağımsız olarak etiketlenmiştir.
- Ham Uyuşma (Raw Agreement):** %90.00 (432 / 480 vaka).
- Cohen's Kappa (κ):** **0.8666** (NLP literatüründe mükemmele yakın uyuma eşiği).

- **Uzlaşma (Adjudication):** Başlangıçta ayrışan 48 vaka (%10.0), yapılandırılmış hakemlik oturumlarında tartışılarak nihai altın etiketlere bağlanmıştır. İnsan denetçilerin dahi %10 oranında müzakereye ihtiyaç duyması, verisetinin kolay bir heuristikle çözülemeyecek gri alanlar barındırdığının kanıtıdır.

2.2. Sınıf ve Alan Dengelemesi (Sıfır Yanlılık)

Modellerin çoğunluk sınıfına oynayarak yapay metrik yükseltmesini önlemek adına veri kümesinde 4 sınıf ve 3 sektör tam simetriyle yapılandırılmıştır:

Boyut	Kategori / Sınıf	Vaka Sayısı	Yüzde Dağılımı	Açıklama
Etiket	supported	120	%25.00	Tüm önermeler bağlam tarafından kanıtlanmaktadır.
Etiket	partially_supported	119	%24.79	Doğru bilgi ile bağlam dışı/zıt bilgi bir aradadır.
Etiket	contradicted	121	%25.21	İddia bağlamla doğrudan çelişmekte, sıfır destek içermektedir.
Etiket	unverifiable	120	%25.00	Bağlamda iddiaya dair ne doğrulama ne yalanlama vardır.
Alan	Finans (Sermaye Piyasaları / Bankacılık)	160	%33.33	SPK, BDDK, TCMB mevzuatları, fon ve takas yönergeleri.
Alan	Hukuk (İş ve Tahkim Mevzuatı)	160	%33.33	İş Kanunu, arabuluculuk, spor tahkim ve yargı kararları.
Alan	Tıp (Klinik ve Farmakoloji)	160	%33.33	KOAH, Alzheimer, onkoloji ve cerrahi kılavuzlar.


3. Metin Uzunlukları ve Dilbilimsel Karmaşıklık Profili

"İddialar kısa mı?" sorusuna yanıt verebilmek amacıyla veri kümesindeki iddia (*claim*) ve bağlam (*context*) metinlerinin morfolojik dökümü çıkarılmıştır.

3.1. İddia ve Bağlam Uzunluk İstatistikleri

Metin Bileşeni	Ortalama	Medyan	Min	Max	Standart Sapma
İddia Kelime Sayısı	17.3	17.0	8	41	4.8
İddia Karakter Sayısı	134.6	130.5	51	333	38.6
Bağlam Kelime Sayısı	67.5	66.0	37	106	13.2
Bağlam Karakter Sayısı	536.5	526.5	252	799	105.8

3.2. İddia Kelime Uzunluğu Kademeleri

[İddia Uzunluk Dağılımı - Kelime Bazında]
Kısa (≤ 12 kelime) :  (68 vaka, %14.2)

Orta-Kısa (13-16 kelime): ██████████ (166 vaka, %34.6)
Orta (17-20 kelime) : ██████████ (132 vaka, %27.5)
Orta-Uzun (21-25 kelime): ██████████ (87 vaka, %18.1)
Uzun (≥26 kelime) : ██████ (27 vaka, %5.6)

Görüldüğü üzere, 12 kelime ve altındaki kısa iddialar veri kümesinin yalnızca **%14.2'sini** oluşturmaktadır. Geriye kalan **%85.8'lik kesim (412 iddia)**, 13 ile 41 kelime arasında değişen, yan cümleler ve bağlaçlarla bağlanan bileşik yapılardan meydana gelmektedir.

4. Gemma-4 QLoRA Atomizasyon Analizi

Doktora tezimizin 0. Bileşeni olarak görev yapan **Gemma-4 QLoRA Atomizer Modeli**, iddiaları bağımsız olarak doğrulanabilir mantıksal önermelere ayırmaktadır.

4.1. Atom Sayısı Dağılımı (İddia Başına)

Veri kümesindeki 480 iddia üzerinden elde edilen önerme frekansları şöyledir:

Önerme Sayısı	İddia Sayısı	Yüzde Payı	Toplam Üretilen Atom	Ortalama Kelime / Atom
1 Atom	46	%9.58	46	13.8 kelime
2 Atom	350	%72.92	700	8.2 kelime
3 Atom	84	%17.50	252	6.9 kelime
4+ Atom	0	%0.00	0	-
TOPLAM	480	%100.0	998	Ort: 8.3 kelime

4.2. Dağılımın Kuramsal Açıklaması: Neden %73 Oranında "2 Atom"?

Literatürde ve tez kurgumuzda **halüsinasyon**, nadiren cümlelerin bütünüyle sıfırdan uydurulması şeklinde ortaya çıkar. En tehlikeli ve tespiti zor halüsinasyon tipi; **doğru bir ana gövdenin içine küçük, yanıltıcı veya çelişkili bir ek iddianın eklenmesidir**.

- Bileşik İddia Yapısı:** TR-FactBench'teki iddialar bilinçli olarak "*Olay A gerçekleşmiştir VE Olay B uygulanır*" biçiminde iki odaklı kurulmuştur. Bu sayede modelin yalnızca bütüne bakarak karar vermesi engellenmiş, atomik denetim zorunlu kılınmıştır.
- Aşırı Parçalamanın (Over-segmentation) Önlenmesi:** Gemma-4 QLoRA eğitiminde uygulanan düzenleme sayesinde model, sıfat tamlamalarını veya edat gruplarını anlamsız parçalara bölmemekte (örn. 5-6 atoma parçalamamakta); cümlelerin bağımsız yargı bütünlüğünü korumaktadır. Bu sebeple 4+ atomlu vaka sayısı 0'dır.

4.3. Atom Sayısı ile Altın Etiketler Arasındaki Çarpaz İlişki

Önerme sayısının iddiaların gerçek etiketleriyle olan ilişkisi aşağıdaki tabloda çarpıcı bir örüntü sunmaktadır:

Sınıf / Etiket	1 Atomlu (46 vaka)	2 Atomlu (350 vaka)	3 Atomlu (84 vaka)	Genel Dağılım (480 vaka)
supported	14 (%30.4)	82 (%23.4)	24 (%28.6)	120 (%25.0)
partially_supported	3 (%6.5)	84 (%24.0)	32 (%38.1)	119 (%24.8)
contradicted	8 (%17.4)	98 (%28.0)	15 (%17.9)	121 (%25.2)
unverifiable	21 (%45.7)	86 (%24.6)	13 (%15.5)	120 (%25.0)

- Kritik Gözlem 1 (Partially Supported Sıçraması):** İddia 1 atomdan oluştuğunda **partially_supported** olma olasılığı yalnızca **%6.5'tir** (çünkü tek bir yargı ya doğrudur ya yanlıştır; parçalı olması için cümle içi niteleyici

çelişkisi gerekir). Ancak atom sayısı 3'e çıktığında **partially_supported** oranı **%38.1'e fırlamaktadır**. Önerme sayısı arttıkça, parçalardan birinin doğru diğerinin desteksiz kalma ihtimali istatistiksel olarak katlanmaktadır.

- **Kritik Gözlem 2 (Unverifiable Yığılması):** 1 atomlu iddiaların neredeyse yarısı (**%45.7**) **unverifiable** sınıfındadır. Yalın ve doğrudan iddia edilen tekil bir eylem bağlamda bulunamadığında doğrudan bilgi yokluğu oluşmaktadır.

5. Niteliksel Vaka İncelemeleri (Qualitative Case Studies)

Gemma-4 Atomizer'in metinleri nasıl ayrıştırdığını gösteren temsilci altın vakalar:

5.1. Vaka 1: Tekil Yargı / Bölünemeyen İddia (1 Atom)

- **Örnek ID:** **tfb_ex_0006** | **Alan:** Finans | **Etiket:** **partially_supported**
- **İddia (21 kelime):** "Üyeler ile müşteriler arasındaki değerlendirme uyumsuzluklarının çözümüne yardımcı olan Meslek Birliği A Değerlendirme Komitesinin bu uyumsuzluklara ilişkin kararları mahkemeler açısından bağlayıcıdır."
- **Gemma-4 Atom Çıktısı (1 Atom):**
- "Üyeler ile müşteriler arasındaki değerlendirme uyumsuzluklarının çözümüne yardımcı olan Meslek Birliği A Değerlendirme Komitesinin bu uyumsuzluklara ilişkin kararları mahkemeler açısından bağlayıcıdır."
- **Analiz:** Cümle iç içe geçmiş bir sıfat-fiil grubu barındırdığı için, model sentaktik bütünlüğü zorla bölmeyip tekil ve sağlam bir önerme olarak bırakmıştır.

5.2. Vaka 2: Tipik 2 Odaklı Bileşik İddia (2 Atom)

- **Örnek ID:** **tfb_ex_0001** | **Alan:** Finans | **Etiket:** **supported**
- **İddia (35 kelime):** "Piyasa Kurumu A, sorumlu kıymetli maden tedarik zincirine ilişkin usul ve esasları Bakanlık A'nın uygun görüşünü alarak uluslararası kriterlere göre belirler; bu düzenlemeler Piyasa Kurumu A üyesi kıymetli maden aracı kuruluşlarıyla Türkiye'deki listeli rafinerileri kapsar."
- **Gemma-4 Atom Çıktısı (2 Atom):**
- "Piyasa Kurumu A, sorumlu kıymetli maden tedarik zincirine ilişkin usul ve esasları Bakanlık A'nın uygun görüşünü alarak uluslararası kriterlere göre belirler."
- "Bu düzenlemeler Piyasa Kurumu A üyesi kıymetli maden aracı kuruluşlarıyla Türkiye'deki listeli rafinerileri kapsar."
- **Analiz:** Noktalı virgülle ayrılan iki bağımsız eylem, birbirinin bağlamını bozmadan iki ayrı doğrulanabilir önermeye ayrılmıştır.

5.3. Vaka 3: Gizli Özne / Tamlama Restorasyonu (3 Atom)

- **Örnek ID:** **tfb_ex_0017** | **Alan:** Finans | **Etiket:** **supported**
- **İddia (23 kelime):** "Kasko sigortasında Dar Kasko teminat gruplarının yalnız bir bölümünü, Kasko ise tamamını kapsar; zorunlu trafik sigortası üçüncü kişilere verilen maddi ve bedensel zararları güvence altına alır."
- **Gemma-4 Atom Çıktısı (3 Atom):**
- "Kasko sigortasında Dar Kasko teminat gruplarının yalnız bir bölümünü kapsar."
- "Kasko sigortası tamamını kapsar." (Cümlede ikinci kez yazılmayan 'sigortası' öznesi başarıyla türetilmiş ve tam önerme yapılmıştır)
- "Zorunlu trafik sigortası üçüncü kişilere verilen maddi ve bedensel zararları güvence altına alır."

- **Analiz:** QLoRA eğitiminin Türkçe dilbilgisine kattığı en kritik kazanım olan özne restorasyonu burada somutlaşmaktadır.

6. Veri Kümesinin Zorluk Seviyesi ve Sistemik Modellenme İhtiyacı

TR-FactBench 480'in zorluk seviyesi, yerel modellerin tekil performansları ve uyumsuzluk oranlarıyla ölçülmektedir:

6.1. Tekil Modellerin Yetersizliği ve Uyuşmazlık

- K1 Modeli (ELECTRA-TR):** Tek başına bütüncül girdi aldığında **81 hata** yapmakta ve **%83.12** doğrulukta kalmaktadır. Özellikle kısmi destek ve ince olumsuzlukları kaçırmaktadır.
- K2 Modeli (Gemma + mDeBERTa):** Tek başına atomik girdi aldığında **94 hata** yapmakta ve **%80.42** doğruluk üretmektedir.
- Uyuşmazlık Alanı (Disagreement):** K1 ve K2 modelleri 480 vakanın **123'ünde (%25.62)** birbiriyle taban tabana zıt kararlar vermiştir.
- Bu 123 uyuşmazlığın **%85.9'u** doğrudan **unverifiable** (36 vaka), **partially_supported** (35 vaka) ve **contradicted** (32 vaka) sınıflarındadır. Modeller **supported** gibi açık olgularda uzlaşıırken, anlamsal sınır bölgelerinde ayrışmaktadır.

6.2. Kademeli Hibrit Mimari ve Meta-Hakem V4 Başarımı

K1 ve K2 modellerinin tek başına yetersiz kaldığı bu 123 uyuşmazlık vakasında Meta-Hakem Llama-3.3-70B devreye girdiğinde sistemik başarımlar dramatik biçimde yükselmiştir:

Sistem Mimarisi	480 Vaka Doğruluk	Doğru Sayısı	Hata Sayısı	Macro-F1	MCC
K2 Tek Başına (mDeBERTa Atomik)	%80.42	386	94	0.8038	0.7410
K1 Tek Başına (ELECTRA-TR Bütüncül)	%83.12	399	81	0.8301	0.7761
Hibrit + Hakem V1 (Baseline)	%89.54	428	52	0.8951	0.8612
Hibrit + Hakem V2 (CoT)	%90.83	436	44	0.9080	0.8785
Hibrit + Hakem V3 (Nötr Atomlar)	%92.50	444	36	0.9252	0.9008
Hibrit + Hakem V4 (Semantik Yükleme)	%93.13	447	33	0.9315	0.9092
<i>Teorik Oracle Tavanı (K1 & K2)</i>	%93.33	448	32	0.9334	0.9118

Zirve Noktası: V4 istemi ile Meta-Hakem, 123 uyuşmazlığın 110'unu doğru çözerek (%89.43 hakem doğruluğu), boru hattını **%93.13'e** ulaştırmış ve kuramsal Oracle sınırına (%93.33) yalnızca **1 vaka mesafede** kalarak veri kümesindeki zorluk eşiğini aşmıştır.

7. Sonuç ve Doktora Tezi İçin Çıkarımlar

- Özgün Kıyaslama Gücü:** TR-FactBench 480, sıradan genel kültür soruları yerine yüksek teknik bilgi yoğunluğuna sahip 3 kritik alanda (Finans, Hukuk, Tıp) kurgulanmış, sıfır sınıf yanlılığına sahip güvenilir bir altın veri kümesidir.
- İddiaların Gerçekçiliği:** İddiaların ortalama 17.3 kelime olması ve %85.8'inin 13 kelimedenden uzun bulunması, benchmark'ın gerçek hayattaki LLM halüsinasyonlarını başarıyla simüle ettiğini gösterir.

3. **Gemma-4 QLoRA Ayrıştırıcısının Yetkinliği:** 998 atomik önermenin tamamının dilbilgisel eksiksizlikle çıkarılması, özne tamamlama yeteneği ve %72.92'lik 2-atom dengesi, modelin tez hedeflerine kusursuz hizmet ettiğini kanıtlamaktadır.
4. **Hibrit Boru Hattının Zorunluluğu:** Veri setinin taşıdığı %25.62'lik model uyumsuzluk oranı, tekil küçük modellerin sınırlarını ve Meta-Hakem ile desteklenen hiyerarşik hibrit mimarinin gerekliliğini tartışmasız biçimde ortaya koymaktadır.